Proyecto final BI · Entrega 2

Data warehouse, ETL y tablero

Vigía Segura S.A.S.: dónde y cuándo crecer frente al hurto a personas

Integrante	Código
Laura Juliana López Loaiza	507252008
Andrey Joel Ordoñez Romero	507232731
Laura Jimena Cardenas Umaña	507231704

Dato	Valor
Docente	Leandro Pájaro Fuentes
Fecha de entrega	[poner la fecha real de entrega]
Repositorio	https://github.com/andreyjoel07zx-afk/bi-proyecto-equipo507232731
Motor de base de datos	PostgreSQL (Neon, base neondb)
Herramienta del tablero	Power BI Desktop

Resumen de la entrega

Se implementó el almacén dimensional de Vigía Segura S.A.S. en PostgreSQL (servicio Neon, base neondb) con los esquemas stg (4 tablas espejo) y dw (estrella): dim_tiempo (1.461 registros), dim_municipio (1.122), dim_perfil_poblacional (12), dim_cobertura (15, SCD tipo 2) y fact_hurto_personas (174.407 registros municipio-día 2022-2025, que suman 1.348.275 víctimas conciliadas al 100 %). La carga completa se ejecuta con un solo trabajo de Pentaho Data Integration 9.4 (job_carga_completa.kjb), que terminó sin errores en 1 min 50 s. Según el tablero de Power BI, los municipios sin sede (de 100.000 habitantes o más) con mayor tasa promedio de hurto a personas 2022-2025 son Pasto (1.552,2 víctimas por 100.000 hab.; de 1.319,8 en 2022 a 1.608,3 en 2025) y Neiva (1.376,0; de 1.439,9 en 2022 a 1.112,1 en 2025). Pasto, con tasa creciente, es la ubicación prioritaria para la primera sede nueva y Neiva la segunda.

1. Modelo físico

1.1 Motor y base de datos

PostgreSQL en la nube (Neon, base neondb), administrado con DBeaver CE 26.2. Esquema stg: stg_f1_hurto_personas, stg_f2_divipola, stg_f3_poblacion y stg_f4_sedes (recepción cruda, todo texto). Esquema dw: 4 dimensiones con llave subrogada y llave natural única, y la tabla de hechos con llaves foráneas a las 4 dimensiones.

1.2 Tablas creadas

Tabla	Tipo	Llave primaria	Llaves foráneas	Registros	Script DDL
dim_tiempo	Dimensión	sk_tiempo	—	1.461	dw/ddl/ 03_tablas_dw .sql, 04_dim_tiem po.sql
dim_municipi o	Dimensión	sk_municipio	—	1.122	dw/ddl/ 03_tablas_dw .sql
dim_perfil_po blacional	Dimensión	sk_perfil	—	12	dw/ddl/ 03_tablas_dw .sql
dim_coberturа	Dimensión (SCD 2)	sk_cobertura	—	15	dw/ddl/ 03_tablas_dw .sql
fact_hurto_pe rsonas	Hechos	sk_hecho	sk_tiempo, sk_municipio, sk_perfil, sk_cobertura	174.407	dw/ddl/ 03_tablas_dw .sql

1.3 Diagrama del modelo físico

1.4 Dimensión de tiempo

dw.dim_tiempo cubre sin huecos del 01/01/2022 al 31/12/2025 (1.461 días). Se pobla con el script dw/ddl/04_dim_tiempo.sql (generate_series), ejecutado como entrada SQL del trabajo de PDI. Atributos: sk_tiempo (YYYYMMDD), fecha, dia, nombre_dia, dia_semana, es_fin_semana, es_festivo (71 festivos de Colombia 2022-2025), mes, nombre_mes, trimestre, semestre y anio.

2. Procesos ETL

2.1 Trabajo de carga

etl/trabajos/job_carga_completa.kjb ejecuta en orden: 01 Crear esquemas → 02 Crear staging → 03 Crear tablas DW → 04 Poblar dim_tiempo → t01 Extraer F2 → 10 Limpiar y cargar dim_municipio → t02 Extraer F3 → 11 Limpiar y cargar dim_perfil_poblacional → t03 Extraer F4 → 12 Limpiar y cargar dim_cobertura → t04 Extraer F1 → 13 Limpiar y cargar fact_hurto_personas. Las dimensiones se cargan antes que los hechos. La conexión dw_neon usa variables de kettle.properties (sin contraseña en el repositorio).

2.2 Transformaciones

Archivo .ktr	Fuente y formato	Destino	Pasos principales	Leídos	Escritos	Rechazos

t01_dim_municipio.ktr + 10_dim_municipio.sql	F2 DIVIPOLA (JSON)	stg_f2_divipola → dw.dim_municipio	JSON input → Table output; SQL: LPAD, coma a punto, región	1.122	1.122	0
t02_dim_perfil_poblacional.ktr + 11_….sql	F3 Población DANE (XLSX)	stg_f3_poblacion → dw.dim_perfil_poblacional	Microsoft Excel input (fila 8) → Table output; SQL: separa Total y Cabecera, 12 perfiles	84.229	12 perfiles	—
t03_dim_cobertura.ktr + 12_….sql	F4 Maestro de sedes (XLSX)	stg_f4_sedes → dw.dim_cobertura	Microsoft Excel input → Table output; SQL: LPAD, fechas, metros a km, Haversine, SCD 2	5	15	0
t04_fact_hurto_personas.ktr + 13_….sql	F1 Hurto a personas (CSV)	stg_f1_hurto_personas → dw.fact_hurto_personas	CSV file input → Table output; SQL: filtro 2022-2025, sin SIN ESTABLECER, agregación municipio-día, búsqueda de llaves	654.716	174.407	480.309

2.3 Reglas de limpieza aplicadas

Problema (Entrega 1)	Fuente y campo	Regla aplicada	Script / paso	Registros afectados
Código no numérico (SIN ESTABLECER)	F1.COD_MUNI	Se descartan	13_fact_hurto_personas.sql	365 (todos de 2008)
Nombre distinto	F1.MUNICIPIO	Se integra solo	13_fact_hurto_p	174.407

al oficial (CALI)		por código DANE	ersonas.sql	
Formato de fecha variable	F1.FECHA HECHO	dd/mm/aaaa o aaaa-mm-dd a DATE	13_fact_hurto_personas.sql	654.716
Cambio de granularidad histórico	F1.CANTIDAD	Se acota a 2022-2025	13_fact_hurto_personas.sql	479.944 descartados
Coma decimal en coordenadas	F2.longitud, latitud	Coma a punto y NUMERIC(9,6)	10_dim_municipio.sql	1.122
Nombre no único (LA UNIÓN)	F2.nom_mpio	cod_dane_mpio CHAR(5) como llave natural única	10_dim_municipio.sql	1.122
Filas de título y notas al pie	F3 encabezado	Lectura desde la fila 8; se filtra MPIO no nulo	t02 (Excel input) y 11_….sql	84.229 leídas
Total mezclado con componentes	F3.ÁREA GEOGRÁFICA	Total y Cabecera por separado	11_dim_perfil_poblacional.sql	13.476 (4.492 Total)
Código sin cero inicial	F4.cod_dane_mpio	LPAD a 5 dígitos	12_dim_cobertura.sql	2
Fechas y unidades mezcladas	F4.fecha_apertura, radio	Fechas a DATE; si radio > 500 se divide entre 1000	12_dim_cobertura.sql	5

2.4 Evidencia de ejecución

Ejecución del 06/11/2026 en Spoon 9.4 sobre neondb: las 14 entradas del trabajo con result=true, 0 errores, duración 1 min 50 s (20:12:05 a 20:13:55).

3. Conciliación

3.1 Conteo por fuente

Fuente	Leídos	Cargados	Descartados	Motivo
F1 (CSV)	654.716	174.407	480.309	479.944 fuera de 2022-2025 y 365 SIN ESTABLECER (de 2008)
F2 (JSON)	1.122	1.122	0	Todos con código válido
F3 (XLSX)	84.229	4.492 filas Total 2022-2025 (12 perfiles)	—	Años 2018-2021 y 2026-2042, filas Cabecera/Rural y notas al pie
F4 (XLSX)	5	5 sedes / 15 estados	0	—

3.2 Totales de una métrica

Métrica	Fuente	DW	Diferencia
Víctimas 2022-2025	1.348.275	1.348.275	0
Víctimas por año	2022: 351.680 · 2023: 391.005 · 2024: 316.216 · 2025: 289.374	Igual	0
Población Total 2022/2023/2024/2025	51.643.565 / 52.117.067 / 52.613.753 / 53.057.212	Igual	0

4. Tablero

4.1 Indicadores

Indicador	Fórmula DAX	Qué mide	Referencia	Pregunta
Tasa de hurto por 100.000 hab.	DIVIDE([Total Victimas], [Poblacion Periodo])*100000	Riesgo relativo por población	Tasa nacional del tablero: 649,8	P0, P2
Variación anual %	DIVIDE([Total Victimas]-[Victimas Anio Anterior], [Victimas Anio Anterior])	Cambio frente al año anterior	Año anterior (0 %)	P3
% víctimas viernes y sábado	DIVIDE(CALCULATE([Total Victimas], nombre_dia IN {"Viernes","Sábado"}),[Total Victimas])	Concentración en días pico	Reparto uniforme 28,6 % (2/7) vs. 32,3 % observado	P1

4.2 Respuesta a las preguntas de negocio

Pregunta	Página y visual	Tipo de gráfico	Respuesta (con cifra)
P0	Página 1 · barras Top 10 y líneas	Barras horizontales para el ranking y líneas para la evolución	Pasto 1.552,2 (sube de 1.319,8 a 1.608,3) y Neiva 1.376,0 (baja de 1.439,9 a 1.112,1); siguen Funza 1.075,2 (área de influencia), Girardot 1.044,0, Villavicencio 1.035,9 y

			Popayán 1.035,4.
P1	Página 2 · columnas por mes y por día	Columnas: comparan magnitudes entre categorías ordenadas	En municipios con sede o área de influencia, octubre (92.088), septiembre (87.846) y agosto (84.598) son los meses pico. Viernes (16,4 %) y sábado (16,0 %) concentran el 32,4 %; el domingo es el menor (11,1 %).
P2	Página 2 · columnas agrupadas	Columnas agrupadas: tamaño en el eje y ruralidad en la leyenda	Grandes urbanos 1.159,5; intermedios urbanos 582,0; pequeños predominantemente rurales 78,2 (14,8 veces menos).
P3	Página 1 · matriz región-departamento y barras por región	Matriz con jerarquía para variación; barras para magnitud	Andina concentra 969.625 víctimas (71,9 %) en 2022-2025. En 2025 todas las regiones bajan (Andina −7,9 %, Pacífica −13,4 %); entre departamentos grandes solo Atlántico sube (+33,2 %).

4.3 Capturas del tablero

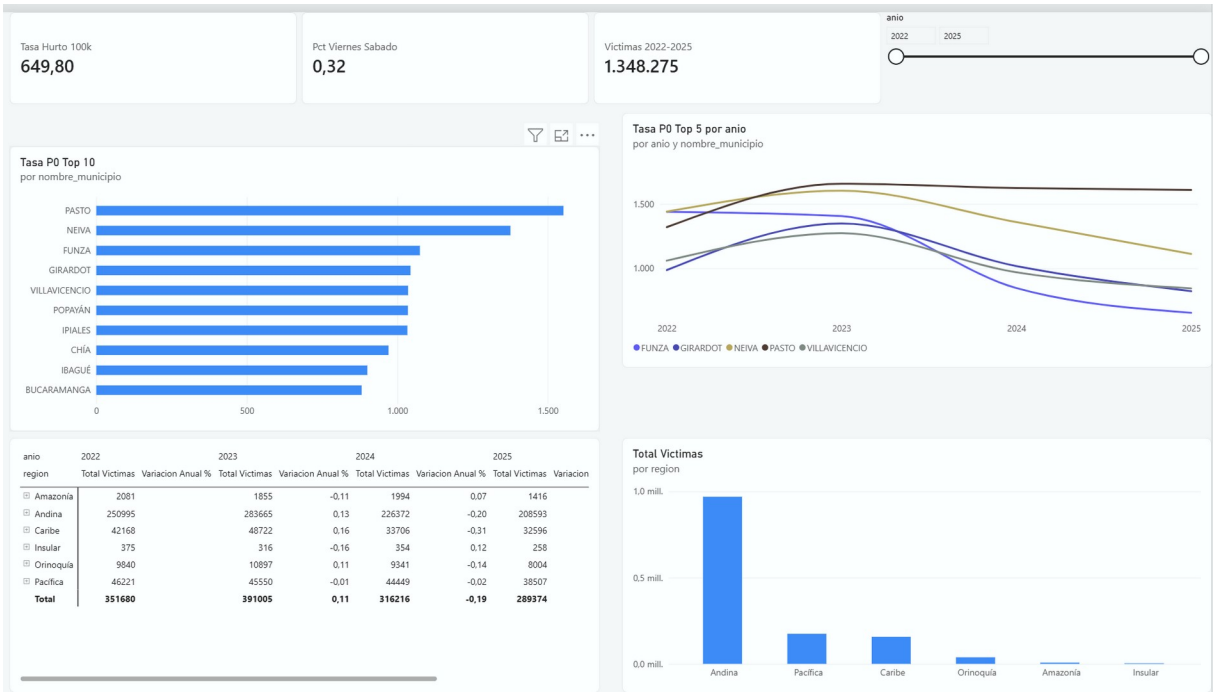


Figura. Página 1 del tablero: indicadores, P0 (top 10 y top 5 por año, municipios sin sede) y P3 (víctimas por región y variación anual).

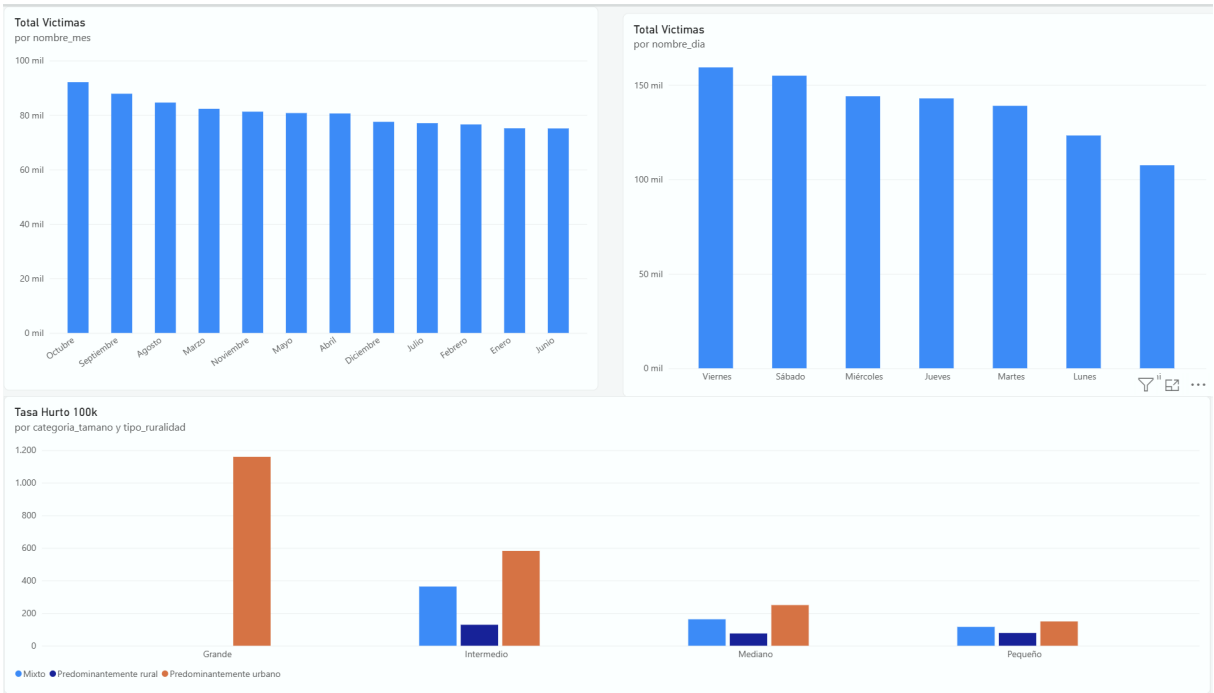


Figura. Página 2 del tablero: P1 (víctimas por mes y por día en municipios con sede o área de influencia) y P2 (tasa por tamaño y ruralidad).

4.4 Filtros

Segmentador de año (rango 2022-2025) sincronizado en ambas páginas. Filtros de objeto visual: estado de cobertura (Área de influencia y Sin cobertura en P0; Con sede y Área de influencia en P1) y año 2025 en la matriz de P3. La matriz permite bajar de región a departamento.

Anexos

Anexo A. Consultas de conciliación: dw/conciliacion/01_conciliacion_carga.sql (incluido en el repositorio).