Business Intelligence

Proyecto final · Entrega 3

Modelo predictivo

Vigía Segura S.A.S.: víctimas de hurto a personas esperadas por municipio

Integrante	Código
Laura Juliana López Loaiza	507252008
Andrey Joel Ordoñez Romero	507232731
Laura Jimena Cardenas Umaña	507231704

Dato	Valor
Docente	Leandro Pájaro Fuentes
Fecha de entrega	07/11/2026
Repositorio	https://github.com/andreyjoel07zx-afk/bi-proyecto-equipo507232731
Entorno del modelo	Python 3 en Google Colab (pandas, scikit-learn, SQLAlchemy), conectado al data warehouse en Neon

Resumen de la entrega

La pregunta P4 de la Entrega 1 pide estimar cuántas víctimas de hurto a personas se esperan por municipio en los próximos seis meses. El modelo predice las víctimas de cada municipio en cada mes con seis meses de anticipación, usando solo información del data warehouse conocida en el momento de la predicción. Se compararon una regresión lineal y un bosque aleatorio sobre la prueba de julio a diciembre de 2025: el bosque aleatorio obtuvo un MAE de 5,79 víctimas por municipio y mes (RMSE 92,6), mejor que la regresión lineal (MAE 9,19) y que la referencia ingenua del mismo mes del año anterior (MAE 6,32), y erró el total del semestre en solo 4,1 %. Para enero a junio de 2026 el modelo espera 136.057 víctimas en los 1.095 municipios, 5,6 % menos que en el mismo semestre de 2025; Bogotá (58.782), Medellín (12.744) y Cali (9.023) concentran la mayor parte, y Pasto (3.182) es el municipio sin sede con más víctimas esperadas, lo que confirma la recomendación de abrir allí la primera sede nueva.

1. Comprensión del negocio

1.1 Pregunta y decisión

Se trabaja la pregunta P4 de la tabla 1.3 de la Entrega 1 (tipo BA): «¿Cuántas víctimas se esperan por municipio en los próximos seis meses?». Con las predicciones, el gerente comercial de Vigía Segura decide en qué municipios reforzar la operación y la venta de servicios de seguridad durante el siguiente semestre: dónde asignar guardas y supervisores, y en qué municipios sin sede priorizar la apertura (Pasto y Neiva, según la Entrega 2) porque se espera que el hurto se mantenga alto.

1.2 Variable objetivo y tipo de problema

Elemento	Respuesta
Variable objetivo	victimas: número de víctimas de hurto a personas por municipio y mes
Tipo de problema	Regresión (se predice una cantidad)
Unidad de predicción	Una predicción por municipio y mes, con horizonte de seis meses

1.3 Criterio de éxito

Criterio: MAE menor a 6 víctimas por municipio y mes en la prueba (julio-diciembre 2025) y menor que el de la referencia ingenua «mismo mes del año anterior». Se eligió 6 porque la mitad de los municipio-mes tienen 0 o 1 víctima y el promedio es 25,7: un error de 6 víctimas es pequeño frente a las ciudades que mueven la decisión y obliga a que el modelo aporte más que repetir el año anterior.

2. Comprensión de los datos

2.1 Consulta de extracción

La consulta está en modelo/extraccion.sql y se ejecuta desde el notebook con SQLAlchemy contra el data warehouse en Neon (esquema dw). Arma una rejilla municipio × mes de enero de 2022 a diciembre de 2025 con los 1.095 municipios que tienen al menos un hecho, suma las víctimas de fact_hurto_personas unida a dim_tiempo por mes (0 cuando no hubo hechos), agrega del calendario de dim_tiempo los festivos y días de fin de semana del mes, y une dim_municipio (nombre, departamento, región), el perfil poblacional y la cobertura más recientes del municipio (dim_perfil_poblacional y dim_cobertura) y la población anual de la vista v_poblacion_municipio_anio. No filtra registros: conserva los meses sin víctimas porque también son información para el modelo.

```
-- modelo/extraccion.sql · Conjunto de datos para la pregunta P4 (Entrega 3)
-- Una fila por municipio y mes (enero 2022 - diciembre 2025), con las víctimas del mes
-- (0 cuando no hubo hechos) y los atributos de las dimensiones conocidos de antemano.
WITH meses AS (                       -- calendario mensual desde dim_tiempo
    SELECT anio, mes,
```

```
           MIN(sk_tiempo)                          AS sk_tiempo_mes,   -- primer día del mes
           SUM(CASE WHEN es_festivo    THEN 1 ELSE 0 END) AS dias_festivos,
           SUM(CASE WHEN es_fin_semana THEN 1 ELSE 0 END) AS dias_fin_semana
    FROM dw.dim_tiempo
    GROUP BY anio, mes
),
municipios AS (                       -- municipios con al menos un hecho en el periodo
    SELECT DISTINCT f.sk_municipio FROM dw.fact_hurto_personas f
),
victimas_mes AS (                     -- hechos agregados a municipio-mes
    SELECT f.sk_municipio, t.anio, t.mes, SUM(f.cantidad_victimas) AS victimas
    FROM dw.fact_hurto_personas f
    JOIN dw.dim_tiempo t ON t.sk_tiempo = f.sk_tiempo
    GROUP BY f.sk_municipio, t.anio, t.mes
),
atributos AS (                        -- perfil y cobertura más recientes de cada municipio
    SELECT DISTINCT ON (f.sk_municipio)
           f.sk_municipio, p.categoria_tamano, p.tipo_ruralidad, c.estado_cobertura
    FROM dw.fact_hurto_personas f
    JOIN dw.dim_tiempo t             ON t.sk_tiempo  = f.sk_tiempo
    JOIN dw.dim_perfil_poblacional p ON p.sk_perfil  = f.sk_perfil
    JOIN dw.dim_cobertura c          ON c.sk_cobertura = f.sk_cobertura
    ORDER BY f.sk_municipio, t.fecha DESC
)
SELECT m.sk_municipio, d.cod_dane_mpio, d.nombre_municipio, d.nombre_departamento, d.region,
       me.anio, me.mes, me.sk_tiempo_mes, me.dias_festivos, me.dias_fin_semana,
       a.categoria_tamano, a.tipo_ruralidad, a.estado_cobertura,
       po.poblacion_total,
       COALESCE(v.victimas, 0) AS victimas
FROM municipios m
CROSS JOIN meses me
JOIN dw.dim_municipio d ON d.sk_municipio = m.sk_municipio
JOIN atributos a        ON a.sk_municipio = m.sk_municipio
LEFT JOIN dw.v_poblacion_municipio_anio po
       ON po.sk_municipio = m.sk_municipio AND po.anio = me.anio
LEFT JOIN victimas_mes v
       ON v.sk_municipio = m.sk_municipio AND v.anio = me.anio AND v.mes = me.mes
ORDER BY m.sk_municipio, me.anio, me.mes;
```

2.2 Descripción del conjunto de datos

El conjunto tiene 52.560 registros (1.095 municipios × 48 meses), de enero de 2022 a diciembre de 2025, sin valores nulos.

Variable	Tipo	Papel	Origen (tabla.columna)	Descripción
victimas	Numérica	Objetivo	fact_hurto_personas.cantidad_victimas (suma por mes)	Víctimas del municipio en el mes
sk_municipio, nombre_municipio	Identificador	Llave	dim_municipio	Municipio (no entra al modelo)
anio, mes	Numérica	Entrada (mes) / división	dim_tiempo.anio, dim_tiempo.mes	Periodo; el mes entra como seno y coseno
dias_festivos, dias_fin_semana	Numérica	Entrada	dim_tiempo.es_festivo, es_fin_semana	Festivos y días de fin de semana del mes
region	Categórica	Entrada	dim_municipio.region	Región natural (6 categorías)
categoria_tamano	Categórica	Entrada	dim_perfil_poblacional.categoria_tamano	Grande, intermedio, mediano o pequeño

Variable	Tipo	Papel	Origen (tabla.columna)	Descripción
tipo_ruralidad	Categórica	Entrada	dim_perfil_poblacional.tipo_ruralidad	Urbano, mixto o rural
estado_cobertura	Categórica	Entrada	dim_cobertura.estado_cobertura	Con sede, área de influencia o sin cobertura
poblacion_total	Numérica	Entrada (log)	v_poblacion_municipio_anio.poblacion_total	Población proyectada del año (DANE)

2.3 Distribución de la variable objetivo

La variable objetivo es muy asimétrica: va de 0 a 16.098 víctimas por municipio y mes (Bogotá), con mediana de 1, promedio de 25,7 y percentil 99 de 373. El 46,1 % de los municipio-mes no registra víctimas y 165 superan las 1.000. Los valores altos no son errores sino las grandes ciudades, por eso no se eliminan y el modelo se entrena sobre log(1 + víctimas).

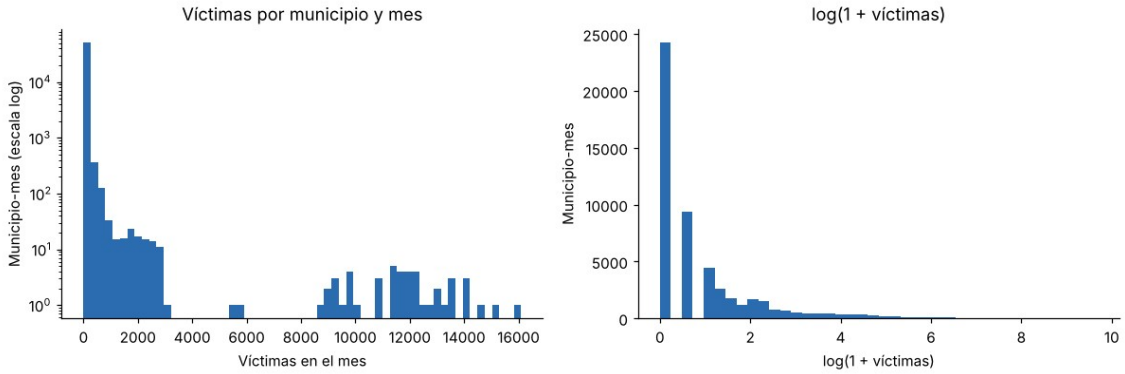


Figura 1. Distribución de víctimas por municipio y mes (izquierda, escala log) y de log(1 + víctimas) (derecha).

2.4 Análisis exploratorio

Se revisó la relación de la variable objetivo con el tiempo, el perfil del municipio y su propia historia.



Figura 2. Víctimas totales por mes.

El total nacional sube en 2023, baja en 2024 y 2025 y tiene un patrón estacional con picos en septiembre y octubre: el mes del año y la tendencia reciente ayudan a predecir.

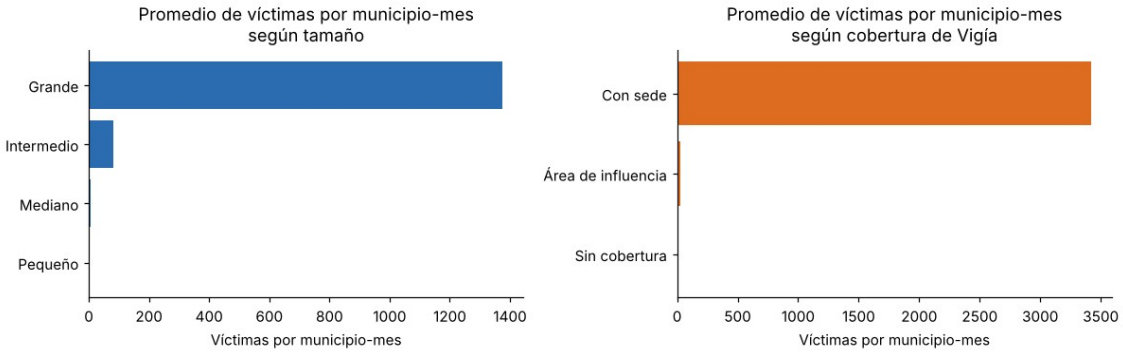


Figura 3. Promedio de víctimas por municipio-mes según tamaño y cobertura.

Los municipios grandes promedian más de mil víctimas por mes y los pequeños menos de una; los municipios con sede de Vigía Segura concentran más víctimas que los que no tienen cobertura. El tamaño y la cobertura separan niveles muy distintos.

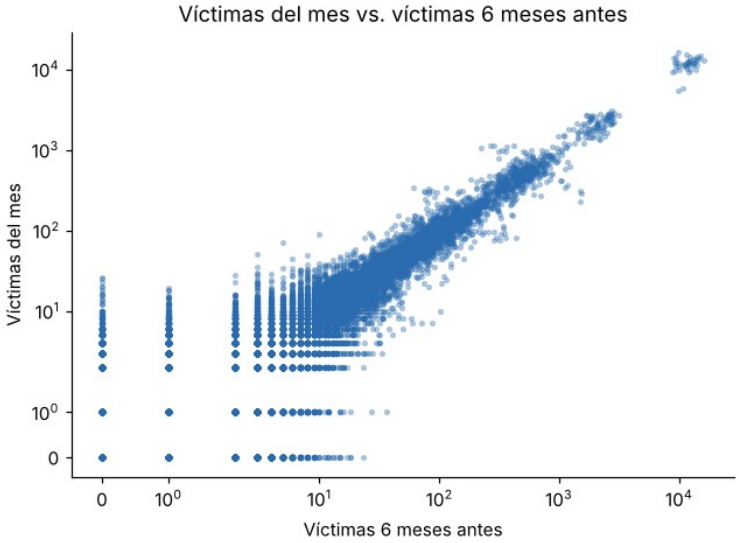


Figura 4. Víctimas del mes frente a las víctimas del mismo municipio seis meses antes.

La relación es casi lineal (correlación 0,979): la historia del municipio, conocida con seis meses de anticipación, es la señal más fuerte para predecir.

3. Preparación de los datos

3.1 Limpieza y transformación

Tratamiento	Variable(s)	Qué se hizo	Registros afectados
Nulos	poblacion_total	Se verificó y se dejó imputación por mediana del municipio (no hubo nulos)	0
Atípicos	victimas	Se conservan (son ciudades reales); el modelo se entrena sobre log(1 + víctimas) para reducir su peso	526 sobre el percentil 99
Historia insuficiente	lag_6 a lag_12	Se descartan los meses de 2022, que no tienen 12 meses previos para calcular los rezagos	13.140

Tratamiento	Variable(s)	Qué se hizo	Registros afectados
Codificación categórica	region, categoria_tamano, tipo_ruralidad, estado_cobertura	One-hot encoding	—
Transformación	mes, poblacion_total	Mes en seno y coseno (ciclo anual); logaritmo de la población	—

3.2 Variables derivadas

Todas las variables derivadas usan solo datos de seis o más meses antes del mes predicho, de modo que se conocen en el momento de hacer el pronóstico.

Variable nueva	Cómo se calcula	Por qué puede ayudar	¿Se conoce antes del hecho?
lag_6, lag_7, lag_8	Víctimas del mismo municipio 6, 7 y 8 meses antes	La demanda reciente conocida al momento de pronosticar anticipa la siguiente	Sí
lag_12	Víctimas del mismo mes del año anterior	Captura la estacionalidad del municipio	Sí
media_6_11	Promedio de víctimas de los meses t−11 a t−6	Nivel estable del municipio, menos ruidoso que un solo mes	Sí
tasa_lag12_100k	lag_12 / población × 100.000	Riesgo relativo del municipio sin depender de su tamaño	Sí

3.3 División en entrenamiento y prueba

Conjunto	Registros	Periodo o proporción
Entrenamiento	32.850	Enero 2023 – junio 2025 (30 meses × 1.095 municipios)
Prueba	6.570	Julio – diciembre 2025 (6 meses × 1.095 municipios)

4. Modelado

4.1 Algoritmos

Los dos algoritmos se entrenaron con el mismo conjunto de entrenamiento, las mismas 27 variables de entrada y la misma transformación log(1 + víctimas) de la objetivo. Como punto de comparación se calculó la referencia ingenua «mismo mes del año anterior».

Algoritmo	Por qué se eligió	Parámetros usados
Regresión lineal	Visto en clase; modelo base interpretable que supone relaciones lineales entre la historia del municipio y las víctimas futuras	Valores por defecto

Algoritmo	Por qué se eligió	Parámetros usados
Bosque aleatorio	Visto en clase; captura relaciones no lineales e interacciones (tamaño × historia) y es robusto a atípicos	n_estimators=300, max_depth=14, min_samples_leaf=3, random_state=42

5. Evaluación

5.1 Métricas sobre el conjunto de prueba

El problema es de regresión. Métricas sobre los 6.570 municipio-mes de la prueba:

Regresión

Algoritmo	MAE	RMSE	Interpretación en unidades del caso
Regresión lineal	9,19	137,33	Se equivoca en promedio 9 víctimas por municipio y mes (MAE); el RMSE de 137 muestra errores grandes en las ciudades con más hurtos. Subestima el total del semestre en 9,8 %
Bosque aleatorio	5,79	92,59	Se equivoca en promedio 6 víctimas por municipio y mes (MAE); el RMSE de 93, mucho mayor, indica que los errores grandes se concentran en pocas ciudades (Bogotá, Medellín, Cali). El total del semestre (139.293 predichas frente a 145.173 reales) difiere 4,1 %
Referencia ingenua (mismo mes 2024)	6,32	102,04	Repetir el año anterior se equivoca en promedio 6,3 víctimas por municipio y mes (RMSE 102) y desvía el total 7,7 %

5.2 Comparación y elección

Se elige el bosque aleatorio porque tiene el menor MAE (5,79 frente a 9,19) y el menor RMSE (92,6 frente a 137,3), es decir, se equivoca menos tanto en el municipio típico como en las grandes ciudades donde los errores pesan más, y además es el único que mejora la referencia ingenua. El RMSE es mucho mayor que el MAE porque los errores se concentran en los municipios grandes: el MAE es cerca de 0,6 víctimas en municipios pequeños, 2 en medianos, 18 en intermedios (promedio real 71) y 274 en grandes (promedio real 1.187, cerca de 23 %). El notebook se ejecutó completo en Google Colab contra el data warehouse en Neon; una ejecución local de verificación sobre una copia idéntica del data warehouse dio MAE 5,82, diferencia mínima que se explica por la versión de scikit-learn.

5.3 Variables más importantes

El promedio de víctimas de los meses t−11 a t−6 (media_6_11) explica cerca del 93 % de la importancia: el nivel reciente del municipio es lo que más determina cuántas víctimas tendrá. Le siguen el tamaño (log de la población), la tasa por 100.000 del mismo mes del año anterior y los rezagos de 12, 6, 8 y 7 meses, que ajustan la estacionalidad. El mes del año, los festivos y la región aportan poco una vez se conoce la historia del municipio.

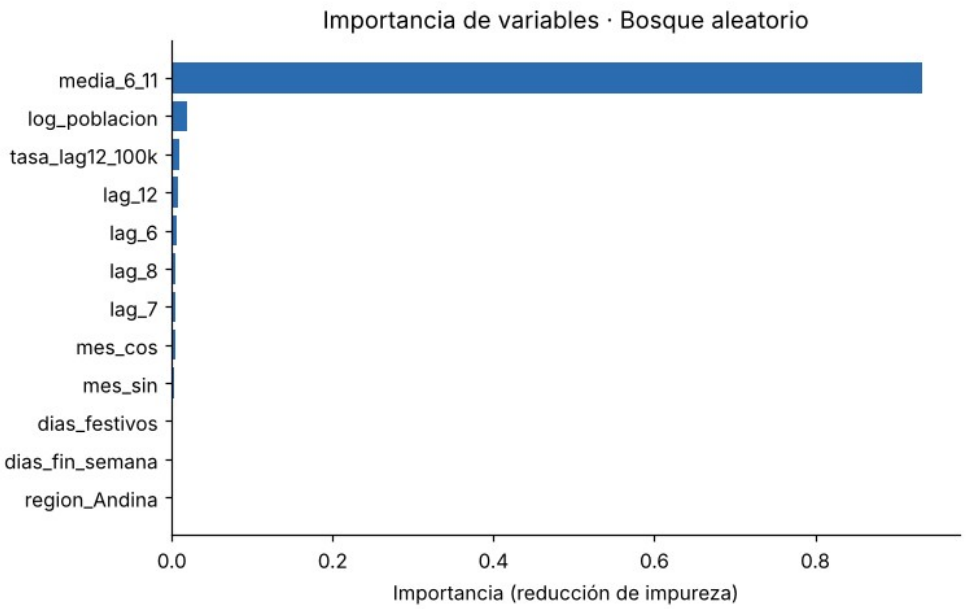


Figura 5. Importancia de variables del bosque aleatorio (12 principales).

5.4 Criterio de éxito

Criterio (sección 1.3)	Valor obtenido	¿Se alcanzó?
MAE menor a 6 víctimas por municipio y mes y menor que la referencia ingenua (6,32)	MAE = 5,79 víctimas por municipio y mes (bosque aleatorio)	Sí

5.5 Respuesta a la pregunta de negocio

El modelo responde la pregunta P4: para el semestre enero-junio de 2026 se esperan 136.057 víctimas de hurto a personas en los 1.095 municipios, 5,6 % menos que las 144.201 del mismo semestre de 2025, con un error esperado de unas 6 víctimas por municipio y mes (4,1 % en el total). Bogotá (58.782), Medellín (12.744), Cali (9.023) y Barranquilla (4.563) seguirán concentrando la demanda en las regionales con sede, y Pasto (3.182 víctimas esperadas) es el municipio sin sede con mayor volumen, seguido de Cartagena (2.974), Ibagué (2.233), Villavicencio (2.200) y Neiva (2.076). La decisión que apoya es reforzar el servicio en las sedes actuales según el volumen esperado de cada municipio y priorizar la apertura de la nueva sede en Pasto, donde además la tasa venía creciendo (Entrega 2).

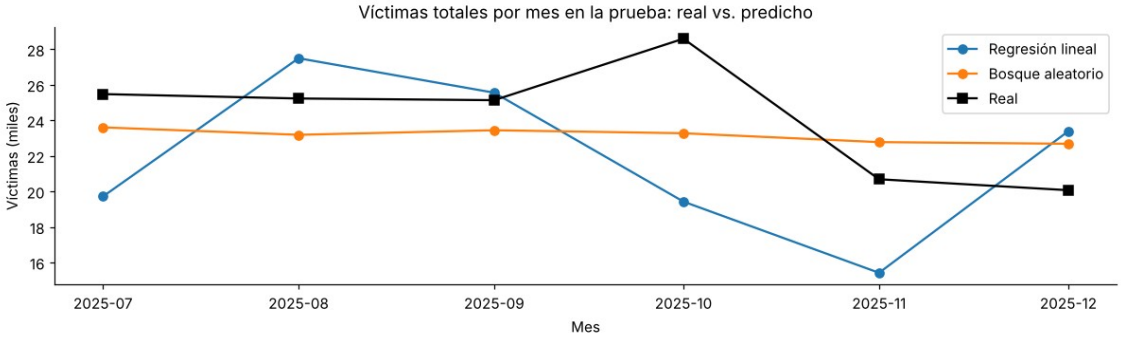


Figura 6. Víctimas totales por mes en la prueba: real frente a predicho.

6. Despliegue

6.1 Tabla de predicciones

Las predicciones del modelo elegido se guardan en la tabla dw.pred_hurto_municipio_mes (script dw/ddl/14_pred_hurto_municipio_mes.sql; carga desde el notebook y script equivalente dw/ddl/15_carga_pred_hurto_municipio_mes.sql). Tiene 13.140 registros: 6.570 de la prueba julio-diciembre 2025 (con el valor real) y 6.570 del pronóstico enero-junio 2026. La llave primaria es (sk_municipio, anio, mes).

Columna	Tipo	Descripción
sk_municipio	INTEGER	Llave a dim_municipio
sk_tiempo	INTEGER	Llave a dim_tiempo (primer día del mes); NULL en 2026, fuera del rango de dim_tiempo
anio, mes	SMALLINT	Año y mes predicho
tipo_periodo	VARCHAR(20)	Prueba 2025 o Pronóstico 2026
victimas_reales	INTEGER	Víctimas reales (solo en la prueba)
victimas_predichas	NUMERIC(10,2)	Predicción del modelo elegido
error_absoluto	NUMERIC(10,2)	|predicho − real| (solo en la prueba)
modelo, fecha_carga	VARCHAR(40), DATE	Algoritmo y fecha de la carga

6.2 Página de predicciones en el tablero

La página «Predicciones vs reales» del tablero de Power BI lee dw.pred_hurto_municipio_mes desde el data warehouse en Neon. Su gráfico principal, titulado «Predicciones vs. valores reales: víctimas de hurto por mes (prueba jul-dic 2025 y pronóstico ene-jun 2026)», muestra las víctimas reales frente a las predichas por mes; arriba están el MAE del modelo (5,79) y el error total de la prueba (−4 %), y abajo el pronóstico de enero a junio de 2026 por municipio. Tiene filtros por tipo de periodo y por región (dim_municipio).

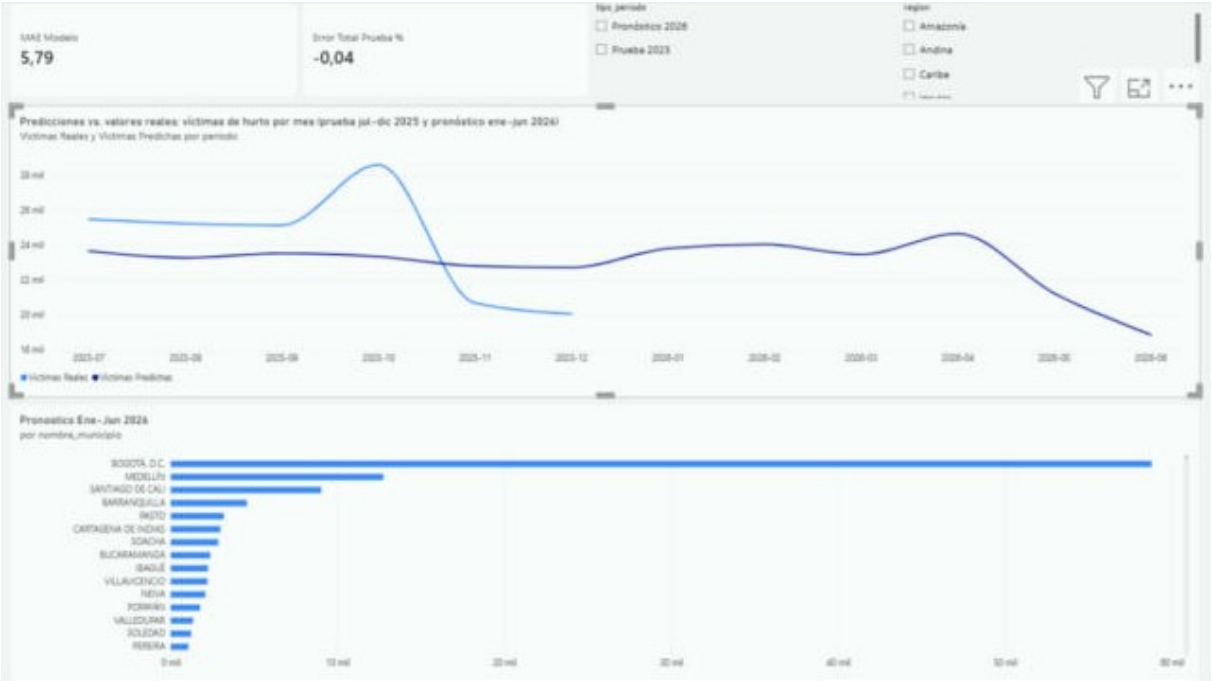


Figura 7. Página de predicciones del tablero.